

# ICA ES TSAI

ANDRIS, BARNA, AND CSABA

ABSTRACT.

## 1. ELOZMENYEK

Unsupervised learning-et szeretnénk individualis framework-ben modellezni. Az ötlet az, hogy az eddigi framework-ot a feje tetejére allítjuk: A tanuló mondja a loss függvényt, a környezet prezentál egy mintát. A loss függvény valami megszorított osztályból jön. Ha pl. surusegfüggvény becslest akarunk ebben a framework-ben modellezni, akkor a loss függvények halmaza olyan  $l$  függvényeket tartalmaz, amelyekre

$$(1.1) \quad \int \exp(-l(x))dx = 1, \quad (\text{vagy konstans})$$

**[CS: Szerintem ez onmagában elég szép dolog, emlékszel, hogy mit szenvedtünk azon, hogy hogyan lehetne nyelvtanulást individualis sorozatos framework-ben kezelni? Hat így lehetne..)]**

Nomost, klasszikusan az ICA arról szól, hogy van  $d$  független forrásod, ezek surusegfüggvényei  $p_{S_1}, \dots, p_{S_d}$ . Legyen  $\mathbf{p}_S$  ezek szorzata. Dobjuk  $\mathbf{S}$ -t ebből ( $\mathbf{S}$  tehát  $d$ -dim vektor). Van egy ismeretlen nemszingularis  $\mathbf{A}^*$  matrix. A megfigyelesed

$$(1.2) \quad \mathbf{X} = \mathbf{A}^* \mathbf{S}$$

keverek. A cél, hogy találjunk egy olyan  $\mathbf{W}$  matrixot, hogy  $\mathbf{W}\mathbf{X}$  komponensei függetlenek. Az adatok  $\mathbf{X}_1, \dots, \mathbf{X}_T$ , ahol  $\mathbf{X}_i = \mathbf{A}^* \mathbf{S}_i$ ,  $\mathbf{S}_1, \dots, \mathbf{S}_T$  független minták  $p_S$ -ből.

Tegyük fel hogy van valamilyen  $p_{\tilde{\mathbf{S}}} = \prod_{i=1}^d p_{\tilde{S}_i}$  tippünk a  $p_S$  eloszlásra. Ideális esetben persze  $p_{\tilde{S}_i} = p_{S_i}$  lenne. A továbbiakban a  $p_{\tilde{S}_i}$  eloszlásokat modeling eloszlásoknak fogjuk hívni. Ekkor a problémát meg lehet egy ML formalizmussal közelíteni:

Használjuk ki, hogy ha  $\mathbf{X} = \mathbf{A}\tilde{\mathbf{S}}$ , akkor

$$p_{\mathbf{X}}(\mathbf{x}) = p_{\mathbf{A}\tilde{\mathbf{S}}}(\mathbf{x}) = \frac{p_{\tilde{\mathbf{S}}}(\mathbf{A}^{-1}\mathbf{x})}{|\det \mathbf{A}|} = p_{\tilde{\mathbf{S}}}(\mathbf{W}\mathbf{x}) |\det \mathbf{W}|$$

Keressünk tehát egy olyan  $\mathbf{W} \doteq \mathbf{A}^{-1}$  matrixot, amelyre

$$L_T(\mathbf{W}) = -\frac{1}{T} \log p_{\mathbf{A}\tilde{\mathbf{S}}}(\mathbf{X}_1, \dots, \mathbf{X}_T)$$

minimalis.

---

*Date:* March 4, 2009.

Tegyük fel, hogy a minták iid-k. **[B: ez nem feltétlenül kellene, vannak eredmények stacionárius sorozatokra is].** Kihasztnálva, hogy

$$\log p_{\mathbf{A}\tilde{\mathbf{S}}}(\mathbf{X}_t) = \log p_{\tilde{\mathbf{S}}}(\mathbf{W}\mathbf{X}_t) + \log |\det \mathbf{W}|,$$

kapjuk hogy

$$(1.3) \quad L_T(\mathbf{W}) = -\log |\det \mathbf{W}| - \frac{1}{T} \sum_{t=1}^T \sum_{i=1}^d \log p_{\tilde{S}_i}(\mathbf{w}_i^T \mathbf{X}_t)$$

ahol  $\mathbf{w}_i^T$  az  $i^{th}$  sora  $\mathbf{W}$ -nek. **[B: ez a keplet megtalálható [Hyv99] 13.oldalan, eredetileg pedig talán [PGJ92] cikkben.]**

Ha az (1.3) egyenlet  $\mathbf{W} = (\mathbf{w}_1^T, \dots, \mathbf{w}_d^T)$ -ben szigorúan konvex, akkor valamely konvex tartományon, akkor a [CBL06] könyv Thm 3.1 ad egy regret korlatot a follow the leader algoritmus regretjére.

**[CS: Ezzel persze meg nem oldottuk meg a teljes puzzle-t. De erről meg majd később. Előjáróban annyit, hogy nem is azt banom, hogy  $p_1, \dots, p_d$ -t ismertnek tetelezzük fel ehhez az analízishez, hanem inkább az érdekel (es erre nem tudom a választ), hogy egy algoritmus, ami a fentiekét implementálja, miért működik "jól" meg akkor is, ha az  $S_1, \dots, S_n$  sorozat korrelált, és a margálisok nem is a  $p_1, \dots, p_d$ -t követik. (Tudod, amikor egy sinust és egy negyszöglet ketteválaszt az algoritmus.)]**

**[B: A sinus és negyszöglet szétválasztásához érdemes lenne a Wiskott fele Slow Feature Analízist (SFA) tanulmányozni [WS02]. Ez arról szól, hogy ha 2 sima függvényt összekeverünk, akkor a keverék kevesbe lesz ezek után sima, emiatt a visszállításhoz a becsült komponensek simaságot kell minimalizálni. E módszer bizonyítottan kapcsolatban áll az ICaval [BBW06], és vannak érdekes alkalmazásai pl bizonyos invarianciák tanulása [WS02]. Az, hogy a keverékből pontosan mikor állíthatók vissza az eredeti sima komponensek viszont tudtommal meg nem ismert. Érdekes lenne egy Darmais-Skitowich tétel szerű elméletet kidolgozni SFA-ra is.]**

## 2. Az ICA EGYERTELMUSEGI KERDESEI

E fejezetben összefoglaljuk hogy mikor, és milyen undeterminanciával állíthatók vissza az ICA komponensek.

A Darmais Skitowich tétel, Cardoso eredményei, Fabain Theis eredményei. Max 1 forrás lehet Gauss i.i.d estben. Bizonyos idosorok eseten több Gauss forrás is lehet. Review on iid and on non-iid cases.

**Definition 2.1** (2 matrix ekvivalens). Azt mondjuk, hogy  $\mathbf{W}_1$  és  $\mathbf{W}_2$  matrixok ekvivalensek ( $\mathbf{W}_1 \sim \mathbf{W}_2$ ), ha megkaphatók egymásból a sorok permutálásával és a sorok atskalazásával, ahol e skalaparaméterek valósak.

## 3. Az ML KOLTSEGFUGGVENY TULAJDONSAGAI

### 3.1. Az ML költségfüggvény konvexitásáról.

**Lemma 3.1.** *A positive definite matrixok halmaza konvex.*

**[B: szigorúan? konvex]**

**Lemma 3.2.**  $-\log |\det(\mathbf{W})|$  függvény szigoruan konvex a positive definite  $\mathbf{W}$  matrixok halmazán.

*Proof.* A konvexitás bizonyítása megtalálható pl itt: 8. tétel a [DCT91] cikknek az 1506. oldalán, valamint [Fan50]. A szigorúság belátható az eredeti bizonyítás elemzésével: Let  $\mathbf{X}_1 \sim \mathcal{N}(\mathbf{0}, \mathbf{K}_1)$ ,  $\mathbf{X}_2 \sim \mathcal{N}(\mathbf{0}, \mathbf{K}_2)$ , where  $\mathbf{K}_1 \neq \mathbf{K}_2$  are positive definite matrices. Kepezzünk mixture eloszlást ezekből, azaz legyen  $\theta$  val. változó  $\mathbf{P}(\theta = 1) = \lambda$ ,  $\mathbf{P}(\theta = 2) = 1 - \lambda$  eloszlással valamilyen  $0 \leq \lambda \leq 1$  értékkel. Legyen  $\theta, \mathbf{X}_1, \mathbf{X}_2$  függetlenek, és legyen a  $\mathbf{Z}$  mixture eloszlás  $\mathbf{Z} = \mathbf{X}_\theta$ . Ekkor  $\mathbf{Z}$  sűrűségfüggvénye:

$$p_{\mathbf{Z}}(\mathbf{z}) = \lambda \mathcal{N}_{\mathbf{z}}(\mathbf{0}, \mathbf{K}_1) + (1 - \lambda) \mathcal{N}_{\mathbf{z}}(\mathbf{0}, \mathbf{K}_2)$$

míg a kovariancia matrixa pedig:  $\mathbf{K} = \lambda \mathbf{K}_1 + (1 - \lambda) \mathbf{K}_2$ . Fix varianciajú eloszlások között a normalisnak a legnagyobb az entropiaja, ezért

$$\begin{aligned} (3.1) \quad \frac{1}{2} \log(2\pi e)^n |\lambda \mathbf{K}_1 + (1 - \lambda) \mathbf{K}_2| &\geq H(\mathbf{Z}) \\ &\geq H(\mathbf{Z}|\theta) \\ &= \frac{\lambda}{2} \log(2\pi e)^n |\mathbf{K}_1| + \frac{1 - \lambda}{2} \log(2\pi e)^n |\mathbf{K}_2| \end{aligned}$$

Emiatt  $\log |\lambda \mathbf{K}_1 + (1 - \lambda) \mathbf{K}_2| \geq \lambda \log |\mathbf{K}_1| + (1 - \lambda) \log |\mathbf{K}_2|$ , tehát  $\log |\det(\mathbf{K})|$  konkav. Továbbá akkor lehetne csak nem szigoruan konkav, ha (3.1) egyenletben egyenlőseggel állna, azaz a  $\mathbf{Z}$  mixture of Gauss is Gauss eloszlású lenne:

$$\lambda \mathcal{N}_{\mathbf{z}}(\mathbf{0}, \mathbf{K}_1) + (1 - \lambda) \mathcal{N}_{\mathbf{z}}(\mathbf{0}, \mathbf{K}_2) = \mathcal{N}_{\mathbf{z}}(\mathbf{0}, \lambda \mathbf{K}_1 + (1 - \lambda) \mathbf{K}_2), \quad \mathbb{R}^n$$

$$\lambda C_{\mathbf{K}_1} \exp\left(-\frac{1}{2} \mathbf{z}^T \mathbf{K}_1^{-1} \mathbf{z}\right) + (1 - \lambda) C_{\mathbf{K}_2} \exp\left(-\frac{1}{2} \mathbf{z}^T \mathbf{K}_2^{-1} \mathbf{z}\right) = C_{\mathbf{K}} \exp\left(-\frac{1}{2} \mathbf{z}^T \mathbf{K}^{-1} \mathbf{z}\right)$$

$$\lambda C_{\mathbf{K}_1} \exp\left(-\frac{1}{2} \mathbf{z}^T (\mathbf{K}_1^{-1} - \mathbf{K}^{-1}) \mathbf{z}\right) + (1 - \lambda) C_{\mathbf{K}_2} \exp\left(-\frac{1}{2} \mathbf{z}^T (\mathbf{K}_2^{-1} - \mathbf{K}^{-1}) \mathbf{z}\right) = C_{\mathbf{K}}$$

A jobb oldal konstans  $\mathbf{z}$ -ben. A bal oldal viszont csak akkor lehet konstans, ha  $\mathbf{K}_1 = \mathbf{K}$ ,  $\mathbf{K}_2 = \mathbf{K}$  azaz  $\mathbf{K}_1 = \mathbf{K}_2$  ami ellentmondás.  $\square$

**Theorem 3.3** ( $L(\mathbf{W})$  konvex). Ha a  $p_i$  szigoruan log-konkav  $\forall i = 1, \dots, d$ , akkor  $L(\mathbf{W})$  (1.3) költségfüggvény konvex a positive definite  $\mathbf{W}$  matrixok konvex halmazán.

[B: szigoruan? konvex. illetve kell-e itt a szigorúság a konkavságban? ... elég lenne ha a  $\log |\det(\mathbf{W})|$  szigoruan konvex...]

**3.2. Az ML költségfüggvény aszimptotikus tulajdonságai.** Felmerül a kérdés, hogy a (1.3) ML költségfüggvény mennyire jó, azaz globalis minimuma vissza adja-e az eredeti  $\mathbf{A}^*$  kevero matrixot, és a  $\mathbf{S}$  rejtett forrásokat. E kérdéssel kapcsolatban Cardoso a következő eredményre jut [Car97] cikkben:

$$(3.2) \quad L_T(\mathbf{W}) = -\frac{1}{T} \sum_{t=1}^T \log p_{\mathbf{A}\mathbf{S}}(\mathbf{X}_t) \xrightarrow{T \rightarrow \infty} -\int p_{\mathbf{X}}(\mathbf{x}) \log p_{\mathbf{A}\mathbf{S}}(\mathbf{x}) d\mathbf{x}$$

$$\begin{aligned}
L_\infty(\mathbf{W}) &= - \int p_{\mathbf{X}}(\mathbf{x}) \log p_{\mathbf{A}\tilde{\mathbf{S}}}(\mathbf{x}) d\mathbf{x} \\
&= \int p_{\mathbf{X}}(\mathbf{x}) \log \frac{p_{\mathbf{X}}(\mathbf{x})}{p_{\mathbf{A}\tilde{\mathbf{S}}}(\mathbf{x})} d\mathbf{x} + \int p_{\mathbf{X}}(\mathbf{x}) \log p_{\mathbf{X}}(\mathbf{x}) d\mathbf{x} \\
&= D(p_{\mathbf{X}} \| p_{\mathbf{A}\tilde{\mathbf{S}}}) + H(p_{\mathbf{X}}) \\
&= D(\mathbf{A}^* \mathbf{S} \| \mathbf{A}\tilde{\mathbf{S}}) + H(\mathbf{A}^* \mathbf{S})
\end{aligned}$$

ahol  $D(\cdot \| \cdot)$  a Kullback-Leibler távolság,  $H$  a differenciális entropia. Mivel az  $\mathbf{A}^* \mathbf{S}$  eloszlás, és így  $H(\mathbf{A}^* \mathbf{S})$  konstans, ezért  $L_\infty(\mathbf{W})$  pontosan akkor minimalis ha az  $\mathbf{A}^* \mathbf{S}$  és  $\mathbf{A}\tilde{\mathbf{S}}$  eloszlása azonos.

**Corollary 3.4.** *Ha az  $p_{\tilde{\mathbf{S}}} = p_{\mathbf{S}}$ , tehát a modeling density perfect, és az összes marginális eloszlás egyforma  $p_{S_i} = p_{S_j}$ , aszimptotikusan meg akkor is visszatudunk állítani egy  $\mathbf{W} \sim (\mathbf{A}^*)^{-1}$  matrixot az ML költségfüggvény globalis minimumaként, azaz az ML költségfüggvény konzisztens. Ha a  $p_{S_i}$  eloszlások különböznek és sorrendjük rögzített, akkor ráadásul meg a  $\mathbf{W}$  soraiban sincs permutációs bizonytalanság.*

**3.3. Az ML költségfüggvény kapcsolata egyéb költségfüggvényekkel.** Van-e más ICA költségfüggvények is: Mutual Information kritérium, marginális entropia összeg kritérium, kurtózis összeg, infomax ICA, stb. Vizsgáljuk meg ezek kapcsolatát az ML költségfüggvénnyel. [Car97] [HO00]

**3.4. Az ML becslesben levo forrasok sorrendjerol.** Az ICAban levo permutációs bizonytalanság azt jelenti, hogy adott költségfüggvény esetén az optimalis  $\mathbf{W}$  mtrix sorainak tetszőleges permutációja is globalis optimuma a költségfüggvénynek.

**Theorem 3.5** (Positive definite halmazokon konvex  $L_T$  esetén a szeparáció egyértelmű). *Tegyük fel, hogy maximum egy forrás Gauss, és a  $p_{\tilde{\mathbf{S}}}$  surusegfüggvények legalább annyira pontosak, hogy  $L_\infty$  minden globalis minimuma szeparálja a forrásokat, azaz  $\mathbf{W} \sim (\mathbf{A}^*)^{-1}$ , és ezek között letezik legalább egy positive definite. Valamelyiket jelölje  $\mathbf{W}_1$ . Megmutatjuk, hogy abban az esetben ha a  $\mathbf{W}$  matrixokat megszorítjuk a positive definite matrixok halmazára, és azokat a  $p_{\tilde{\mathbf{S}}}$  surusegfüggvényeket tekintjük melyek mellett  $L_T(\mathbf{W})$  konvex ezen a konvex tartományon, akkor ez esetben már nem lesz igaz a permutációs bizonytalanság, azaz hogy szeparáció esetén  $\mathbf{W}$  sorainak sorrendje tetszőleges lehetne, hanem pontosan egy ilyen  $\mathbf{W}$  letezik ( $\mathbf{W}_1$ ), meg abban az esetben is ha az összes  $p_{\tilde{S}_i}$  azonos.*

*Proof.* Mivel  $L_T(\mathbf{W})$  konvex minden  $T$ -re, ezért  $L_\infty(\mathbf{W}) = \lim_{T \rightarrow \infty} L_T(\mathbf{W})$  is konvex  $\mathbf{W}$ -ben. Ebből következően vagy 1 darab, vagy végtelen sok globalis minimuma van, és a globalis minimumok konvex tartományt alkotnak. Azt kell belátnunk, hogy a  $\mathbf{W}_1$  sorainak semelyik permutáltja nem lehet globalis minimum. Ha ugyanis  $\mathbf{W}_2$  a  $\mathbf{W}_1$  sorainak egy ilyen globalis minimot adó permutáltja lenne, akkor  $\lambda \mathbf{W}_1 + (1 - \lambda) \mathbf{W}_2$  is globalis minimum lenne, s így ICA szeparáló matrix minden  $\lambda \in [0, 1]$  esetén. Ez azonban ellentmondás mert tudjuk hogy az összes ICA megoldás a  $\mathbf{W}_1$ -gyel ekvivalens matrix – azaz sorainak permutációja és esetleg atskalozottja – kell hogy legyen, míg a  $\lambda \mathbf{W}_1 + (1 - \lambda) \mathbf{W}_2$  matrixok között nyilván van amelyik nem ilyen alakú.  $\square$

Osszefoglalva az a helyzet, hogy ha az  $\mathbf{A}^*$  kevero matrix egy permutációja pozitív definit, akkor letezik pozitív definit megoldás a  $\mathbf{W}$ -re, és ez egyértelmű. Ebben az esetben lehet hatékony az algoritmus. **[B: az latom, hogy ha  $\mathbf{A}^*$  positive**

definit az  $\mathbf{A}$  is, hisz akkor inverze is az. De miért jó az is, ha valamely  $\mathbf{P}$  permutációs mátrixra  $\mathbf{PA}^*$  positive definite?

[B: Egyebeként az is elég lenne, ha tudnánk úgy tovább keverni valamilyen  $\mathbf{B}$  mátrixszal  $\mathbf{X} = \mathbf{A}^* \mathbf{S}$  megfigyelesek (preprocessing), hogy a  $\mathbf{BX} = \mathbf{BA}^* \mathbf{S}$ -ben  $\mathbf{BA}$  már positive definite legyen, meg ha  $\mathbf{A}$  nem is volt az.]

[CS: Mik azok a mátrixok amiknek van olyan permutációja ami pozitív definit? (Ugy értem, intuitive.. Vagy valami ekvivalens atfogalmazásban..)]

Megoldás lehetne meg, hogy feltételezzük a források már fehérek, és akkor nem kellene a  $\log |\det \mathbf{W}|$ -t használni az (1.3) egyenletben, ekkor azonban az ortogonális mátrixok között kellene keresni, ez a manifold viszont nem konvex...

[B: érdekes, hogy általában az ICA algoritmusok azzal kezdődnek, hogy fehéritsük az adatokat, mert ezután már csak egy ortogonális mátrixot kell keresni. A mi módszerünkben viszont nem szabad fehériteni, mert azután a domain amin optimalizálnunk már nem lenne konvex :)]

[Cs: Lehet, hogy többszörös sajátértékek vannak és minden  $p_i$  azonos. Pl. legyen  $\mathbf{A} = \mathbf{I}$ . Ekkor minden páros permutációhoz tartozó permutációs mátrix is megoldás, nem? A determinánsa ezeknek a mátrixoknak 1, és a kritérium második részét nem változtatják tegyük fel, hogy a minta szimmetrikus, vagy végtelen sok van belőle, vagy  $\sum_i -E[\log p_i((\mathbf{WX})_i)]$ -re cseréltük ezt. Azaz ki mondta, hogy  $\log \det(\mathbf{W})$  szigorúan konkáv? Nem az. Mint ahogy a második rész sem az. Ugy tényleg legalábbis. Hmm, ez érdekes. Megjegyzem a páros permutációkhoz tartozó mátrixok nem pozitív definitek, vegyük pl azt aki  $1 < - > 2 > 3 < - > 4$  cserét csinál. Az  $1 \times 1$ -es minor a  $(0)$  mátrix, így nem pozitív definit, stb. Viszont mivel a páratlan permutációk determinánsa  $-1$ , ezekre a kritérium végtelent ad. Ezek nem jönnek szóba sem! Hu de furcsa ez.]

#### 4. EGY LINEÁRIS ALGEBRAI KÖVETKEZMÉNY

**Theorem 4.1** (Positive definit mátrixok sorainak permutációjáról). *Legyen adott egy tetszőleges positive definite  $\mathbf{W}_1$  mátrix, és egy tetszőleges  $\sigma$  permutáció. Ha  $\mathbf{W}_1$  sorait megpértaljuk  $\sigma$  szerint akkor a keletkező  $\mathbf{W}_2$  mátrix pontosan akkor lesz positive definite, ha a  $\sigma$  permutáció az identitás volt.*

*Proof.* A feladathoz hozzárendelhető egy olyan ICA feladat melyben  $\mathbf{A}^* = \mathbf{W}_1^{-1}$ , és minden  $p_{S_i}$  surusegfüggvény azonos log-konkáv, de nem Gauss. Ekkor  $\mathbf{W}_1$  globális minimuma lesz  $L_\infty$ -nek, ami permutáció invariáns  $\mathbf{W}$  soraira nézve, így  $\mathbf{W}_2$  is globális minimum lesz. No de  $L_\infty$  konvex, így  $\lambda \mathbf{W}_1 + (1-\lambda) \mathbf{W}_2$  is globális minimum lenne, s így ez ICA szeparáló mátrix lenne minden  $\lambda \in [0, 1]$  esetén. Ez viszont ellentmondás, mert e mátrixok között kell lenni olyannak ami nem ekvivalens  $\mathbf{W}_1$ -gyel, és így nem lehet szeparáló mátrix. Emiatt  $\mathbf{W}_2$  nem lehet eleme a positive definite mátrixok halmazának.  $\square$

[B: Ismert ennek az állításnak más elemi bizonyítása is?... Kihasználva pl. valahogy, hogy tudjuk, a permutáció után is  $\mathbf{W}$ -nek szimmetrikusnak kell maradnia, és minden principa minorjal positive definite kell hogy legyen...]

**[B: Vajon itt kell e szimmetria  $\mathbf{W}$ -ben, vagy elég az, hogy a sajátértékek mind pozitívak?]**

## 5. ICA-BAN LOKALIS ES GLOBALIS OPTIMUMOK VIZSGALATA

Irodalmi attekintes, one bit matching problema, ML-ICA with modelling density (amikor az igazi density-t nem tudjuk). Eredmenyek, and open questions.

Bizonyos forrasokra es koltsefguggvenyekre egyebken van eredmeny arra, hogy annak a koltsefguggvenynek minden lokalis optimum jo ICA megoldast ad, tehat gradiens modszerek használhatók. De ez egyelőre meg csak 2 forras eseten bizonyított, több forras eseten nyitott problema [GM08]. Ez a cikk arra az esetre bizonyít, amikor a koltsefguggveny a kurtózis, es a forrasok kozott nincs zero kurtózis. E cikkben szinten a lokalis optimumokat akarjak elkerulni: [BZBJ05]

Az ismert, hogy bizonyos ICA koltsefguggvenyek bizonyos forrasokon sok lokalis es not feasible optimummal rendelkeznek. A feladatunk az hogy olyan koltsefguggvenyt, eloszlasokat, es a kevero matrixra domaint allapitsunk meg, ahol a keletkezo feladat egy konvex halmazon torteno konvex optimalizalas lesz.

## 6. CSABA OSOREG KERDESE, NON-IID SOURCES

Hogy lehet, hogy az iid sorozatokra (azaz minden forras egy iid sorozat) kigyezett ICA algoritmusok nagyon jól mukodnek akkor is, ha a sorozatok nem iid-k?

**[CS: Asszem ezt most megerttettem, legalabbis egy aspektusat (egy csomo mindent irtam kozben, amitol megerttettem, amit most kitoroltem, mert mar ertem mi van.. milyen jo, hogy levelezunk;) Nyilvan ez is kozismert, stb. Mindegy.. Itt van amit kigondoltam:]**

**[B: Latom, jo hangulatban voltál ☺]**

**[B: errol a kerdesrol lasd meg a Section 1 beli SFA-s megjegyzesem.]**

Legyen az egyszeruseg kedveert ket forrasunk:  $\{X_1, X_2, \dots\}$  es  $\{Y_1, Y_2, \dots\}$ . Lehet, hogy ezek nem iid sorozatok. Viszont tegyük fel, hogy azert fuggetlenek, hiszen ICA-rol van szo.

A konkrétság kedveert vegyük a korábban diszkutált modszert. Legyen az  $X_t$ ,  $Y_t$  marginalisai a  $t$ -edik pillanatban  $p_{X,t}$ , illetve  $p_{Y,t}$  (lehet, hogy ezek azonosak, de ezt most nem tesszük fel). Itt most feltettük, hogy a surusefguggvenyek leteznek stb.

Ha a  $\mathbf{W}$ -vel visszeforgatott folyamatok  $X'_t, Y'_t$ , akkor egy lehetséges minimalizálható kritérium  $\mathbf{W}$ -ben

$$J_n(\mathbf{W}) = F(\mathbf{W}) - \sum_{t=1}^n \log(p_{X,t}(X'_t)p_{Y,t}(Y'_t)).$$

Itt  $F(\mathbf{W})$  az ominózus log det-es tag. Itt a csavar az elozoekhez kepest az, hogy ez nem ugyanaz, mint ami a maximum likelihood-bol kijonne. Ugyanis ez

$$F(\mathbf{W}) - \log p_{X,1:n}(X'_1, \dots, X'_n)p_{Y,1:n}(Y'_1, \dots, Y'_n),$$

lenne, ahol  $p_{X,1:n}$  (ill.  $p_{Y,1:n}$ ) az  $(X_1, \dots, X_n)$  (ill.  $(Y_1, \dots, Y_n)$ ) egyutttes surusefguggvenyei.

$$(6.1) \quad J_n(\mathbf{W}) = F(\mathbf{W}) - \sum_{t=1}^n \log(p_{X,t}(X'_t)p_{Y,t}(Y'_t)),$$

$$(6.2) \quad J'_n(W) = F(\mathbf{W}) - \log p_{X,1:n}(X'_1, \dots, X'_n)p_{Y,1:n}(Y'_1, \dots, Y'_n)$$

Azt allitom, hogy (\*) megis értelmes kritérium. Ez mindösszesen annyin múlik, hogy minden rögzített  $t$ -re az  $X_t, Y_t$  együttes sűrűségfüggvénye is szorzat alakra bomlik, amikben  $p_{X,t}$  és  $p_{Y,t}$  fognak szerepelni. Ez ugye trivi. Nomost, miért ne vehetnek ezek szorzatot, annak a logaritmusát, stb.

Ebből talán kijön, hogy minden olyan  $\mathbf{W}$ , ami valóban visszaállítja az  $X_t, Y_t$ -t  $J_n(\mathbf{W})$ -t minimalizálja (tartassuk  $n$ -t végtelenbe, tegyük fel mindenféle korlátosságot, legyen ergodicitás, stb., mittomen). Azaz  $J_n(\mathbf{W})$  értelmes kritérium.

A kulcs valahogy az ebben a gondolatmenetben, hogy a margálisok szorzata minden rögzített  $t$ -re előállítja  $X_t, Y_t$  együttes eloszlásfüggvényét. És ehhez nem kell semmit feltenni arról, hogy  $X_t$  (vagy  $Y_t$ ) maga iid. A másik kulcs, hogy  $\mathbf{W}$ -ben nincs olyan sok szabadsági fok (ezt meg nem használtuk). Emiatt az ember azt gondolja, hogy ahogy  $n \rightarrow \infty$ , a kritériumfüggvény egyre definitebb felületet ad. Meg azt is megkockáztatom, hogy értelmes esetekben  $\arg \max_{\mathbf{W}} J_n(\mathbf{W})$  egy valószínűséggel tart az ICA feladat megoldásainak halmazához (azaz a módszer konzisztens).

Ez egy kicsit arra is ramutatna, hogy ha az iid esetre be tudja azonosítani az ember azokat a kritériumokat, amik konzisztenciahoz vezetnek, akkor ebből mellesleg kijöhet a nem iid folyamatokra is egy-egy konzisztencia bizonyítás.

Azaz, általánosabban, tegyük fel hogy a kritériumunk

$$J_n(\mathbf{W}) = F(\mathbf{W}) - \sum_{t=1}^n L_t(X'_t, Y'_t)$$

alaku és beláttuk, hogy iid folyamatokra  $\arg \max_{\mathbf{W}} J_n(\mathbf{W})$  konzisztens. Kérdés: Következik-e ebből, hogy nem iid de pl. (stac) ergodikus folyamatokra is konzisztens a becslés. **[CS:Barna: Van ilyen eredmény? Vagy nem igaz?] [B: Ugy emlékszem Pham-nak vannak eredményei ezzel kapcsolatban, megnezem, beirom majd hogy pontosan mit csinált]**

**[CS:Most eltavolodtunk az individualis sorozat temakortol, de talan nem baj. Majd meg visszaterhetunk rajuk, de asszem eloszor ilyen dolgokat erdemes tisztazni.]**

Folytatva az előző gondolatmenetet nezzük csak, mi lesz, ha  $n \rightarrow \infty$ . Ekkor, ergodicitást felteve,

$$(6.3) \quad \lim_{n \rightarrow \infty} J'_n(\mathbf{W})/n = \lim_{n \rightarrow \infty} -1/n \sum (\log P_{X_i}(X'_i) - \log P_{X'_i}(X'_i) + \log P_{X'_i}(X'_i) + \text{ugyanaz } Y\text{-ra}) \\ = D(P_{X'} || P_X) + H(X') + D(P_{Y'} || P_Y) + H(Y')$$

ahol  $D(p||q)$  a KL-divergencia-rata,  $H$  pedig az (differential)entropy-rate. Ennek a minimuma pedig a  $H(X, Y) = H(X) + H(Y)$  - legalábbis diszkrét esetben -, hiszen az eredeti  $J$  költségfüggvényünk (az eltűnő  $F(\mathbf{W})$  tagtól eltekintve) éppen az, hogy milyen hosszan tudjuk tomoríteni az  $X', Y'$  sorozatot, ami viszont - mivel  $\mathbf{W}$  invertálható - ugyanannyi kell legyen, mint amennyire az  $X, Y$ -t tudjuk.

Ha a  $J_n$  - betunkenti vagy függetlenséget feltételező - kriteriumot vesszük, akkor (\*)-ban nem a rákat, hanem az 1D margálisok divergenciáját és entropiáját kapjuk. Mivel a  $P_X = P'_X$  és  $P_Y = P'_Y$  minimalizálja (\*)-ot, az igazi függetlenítő  $\mathbf{W}$  mindkét esetben jó megoldás, és nagyjából az is látszik, hogy ugyanolyan feltételek mellett nem lesz más megoldás. **[A: de azt most nem látom, hogy ez miért lenne mindig egyedi. Az a gyanúm, hogy erre elég sok eredményt lehetne találni (kicsit belenéztem ica-s cikkekbe - blind source separation címszó alatt), és ott az látszik, hogy jó sokat foglalkoznak azzal, hogy az algoritmusok mikor kerülnek lokális minimumba.]**

**[B: igen sok cikk vizsgálja ezeket, és sok reszeredmény van. Megpróbálok majd utána nézni ezeknek. De nagy általánosságban eredmények meg nem ismertek szerintem.]**

**[B: Vannak olyan eredmények is, amik az ICA ML megközelítésében azt vizsgálják, hogy mi történik ha a surusegfuggvényeket nem ismerjük pontosan csak közelítőleg. Lásd pl Cardoso eredményei: [Car97].**

**A feltelezett surusegfuggvényeket szokás modeling surusegfuggvényeknek is hívni. A sejtés az, hogy elég azt tudni (jól megbecsülni) hogy a surusegfuggvények sub vagy supergauss-ok. Cardoso and Laheld, 1996; Hyvärinen and Oja, 1998; Lee et al., 1999]**

## REFERENCES

- [BBW06] T. Blaschke, P. Berkes, and L. Wiskott. What is the relation between slow feature analysis and independent component analysis? *Neural Computation*, 18(10):2495–2508, 2006.
- [BZBJ05] M. Babaie-Zadeh, B. Bahmani, and C. Jutten. Ica by mutual information minimization: An approach for avoiding local minima. In *EUSIPCO2005*, 2005.
- [Car97] J. F. Cardoso. Infomax and maximum likelihood for source separation. *IEEE Signal Processing Letters*, 4(4):112 – 114, 1997.
- [CBL06] N. Cesa-Bianchi and G. Lugosi. *Prediction, Learning, and Games*. Cambridge University Press, 2006.
- [DCT91] A. Dembo, T. M. Cover, and J. A. Thomas. Information theoretic inequalities. *IEEE Transactions on Information Theory*, 37(6):1501–1518, 1991.
- [Fan50] K. Fan. Information theoretic inequalities. *Proc. Natl. Acad. Sci. USA*, 36(1):31–35, 1950.
- [GM08] F. Ge and J. Ma. Analysis of the kurtosis-sum objective function for ica. In *ISNN '08: Proceedings of the 5th international symposium on Neural Networks*, pages 579–588, Berlin, Heidelberg, 2008. Springer-Verlag.
- [HO00] A. Hyvärinen and E. Oja. Independent component analysis: Algorithms and applications. *Neural Networks*, 13(4-5):411–430, 2000.
- [Hyv99] A. Hyvärinen. Survey on independent component analysis. *Neural Computing Surveys*, 2:94–128, 1999.
- [PGJ92] D. T. Pham, Ph. Garat, and C. Jutten. Separation of mixture of independent sources through a maximum likelihood approach. *Signal Processing, Proceeding EUSIPCO '92*, 6:771–774, 1992.
- [WS02] L. Wiskott and T. J. Sejnowski. Slow feature analysis: unsupervised learning of invariances. *Neural Computation*, 14(4):715–770, 2002.